数据分析及实践 实验二 实验报告

崔士强 PB22151743

2024年3月28日

任务 1

读取后得到的 page.txt 文件如图所示:

```
NOTICE THE PARTY OF P
```

图 1: page.txt 文件内容

任务 2

通过观察可以发现, track 名称跟在<h2 id=后, 对应设计正则表达式:

title_pattern = '<h2 id=.{1,100}>.{1,100}</h2></header>'

输出 5 个 track 名称:

Research Track Full Papers Applied Data Track Full Papers Hands On Tutorials Lecture Style Tutorials Workshop Summaries

图 2: 各个 track 名称

任务3

首先根据任务 2 中的规律,将字符串按 track 进行初步分割,再按照论文进一步分割. 对于目标元素,观察网页代码发现如下规律:

- 1. 作者姓名在<span itemprop="name"之后
- 2. 论文标题在之后
- 3. 收录起始页与终止页在之后

对应设计正则表达式之后利用split()方法取得目标字符串. 对论文进行计数的结果如图 所示

```
print(len(track1dict["papers"]))
    print(len(track2dict["papers"]))

... 313
    183
```

图 3: 两个 track 的论文计数

任务 4

存入kdd23.json文件后如图所示

```
D ModFillow X

(1 ModFillow X)

(1 ModFillow X)

(1 ModFillow X)

(2 ModFillow X)

(3 ModFillow X)

(4 ModFillow X)

(5 ModFillow X)

(6 ModFillow X)

(7 ModFillow X)

(8 ModFillow X)

(8 ModFillow X)

(9 ModFi
```

图 4: kdd2023.json

任务 5

第一步是获取每个作者主页的链接,方法与任务 3 中大致相同. 之后利用request库逐个读取链接. 观察网页代码可以发现, publishInfo可能包括: 1). volume 2). issue 3). pagination. 因此逐个使用try...except 语句查找, 之后进行连接.

最后将信息写入researchers.json文件,如图所示:

图 5: name